WS26/27 AM1: Quantitative Linguistik: Eine Einführung in die Statistik

Arbeitsblatt 1: Übersicht zu R

Eva Scheel

1 Informationen

- **Abgabe**: 3.11.2026 um 24:00 per email an eva.scheel-huber@uni-koeln.de
- **Abgabeformat**: .R-Skript
- **benötigte Daten**: SUBTLEX-UK_selection.csv, auf Sciebo verfügbar

2 Datensatz

In diesem Arbeitsblatt verwenden wir *Subtlex-UK* (Heuven et al. 2014), welches englische Wörter und deren Häufigkeiten in britischen Fernsehsendungen enthält. Der Ausschnitt, mit dem ihr hier arbeiten wird, beschränkt sich auf die folgenden Variabeln:

- Das Wort
- Worthäufigkeit
- Das Lemma und die Wortkategorie (*part-of-speech (POS)*) dessen
- Und ein Maß für *Contextual Diversity (CD)*: Prozentsatz von Filmen, die das Wort enhalten

Für mehr Informationen zu dem Datensatz und für welche linguistische Fragenstellung dieser verwendet werden kann, lies den Artikel von Heuven et al. (2014).

Der Datensatz ist frei verfügbar und kann hier runtergeladen werden.

3 Aufgaben

Lade den Datensatz runter, erstelle ein neues RProjekt und öffne ein neues R-Skript. In dem R-Skript wirst du die Aufgaben ausführen und die Fragen beantworten. In Kommentaren (#) kannst du im Skript angeben, welche Aufgabe oder Frage du mit dem Code erfüllst oder beantwortest.

Beispiel (erfunden):

```
# Aufgabe 10.2
data_new <- data |>
    mutate(new_column = 1:nrow(data))
```

Benutze allgemein gerne Kommentare, um dein Code zu dokumentieren und besser verständlich zu machen.

Wie in dem Seminar, werdet ihr die folgenden vier Schritte durchgehen: 1) Daten einlesen 2) Daten einlesen 3) Daten vorverarbeiten & "reinigen" und 4) vorverarbeitete Daten speichern. Für manche Fragen/Teilaufgaben brauchst du Funktionen, die wir im Seminar nicht besprochen haben. Benutze dafür die Informationsquellen, die im Kurs erwähnt worden sind.

1. **Daten einlesen**: Lese die *Subtlex-UK*-Daten als Data Frame in R ein.
2. **Daten untersuchen**
   2.1.Wie viele Zeilen und wie viele Spalten hat der Datensatz?
   2.2 Wie heißen die Spaltennamen?
   2.3 Gibt es leere Felder, sogenanne *NA*s?
3. **Daten vorverarbeiten**
   3.1 Für linguistische Studien (z.B. psycholinguistische Experimente wie Worterkennungsstudien) verwenden wir Worthäufigkeit oftmals auf der logarithmischen Skala. Füge also eine neue Spalte ein, die die Worthäufigkeit auf der logarithmischen Skala beinhaltet.
   3.2 Nun erstellst du einen neuen Data Frame, welcher nur Wörter beinhaltet die mindestens zwei und höchstens zehn Charaktere lang sind.
   3.3 Ändere den neuen Datensatz so, dass er alle Spalten bis auf *Contextual Diversity* beinhaltet.
   3.4 Wie viele Zeilen hat der neue Data Frame?
4. **Daten speichern**
   4.1 Speichere den neuen Data Frame in einer Datei. Wähle einen passenden Dateinamen aus.

SUMMARISE?

Quellen

Heuven, W. J. B. van, P. Mandera, E. Keuleers, and M. Brysbaert. 2014. "SUBTLEX-UK: A new and improved word frequency database for British English." *The Quarterly Journal of Experimental Psychology* 67: 1176–90. https://doi.org/https://doi.org/10.1080/17470218.2013.850521.