WS26/27 AM1: Quantitative Linguistik: Eine Einführung in die Statistik

Arbeitsblatt 1: Übersicht zu R

Eva Scheel

1 Informationen

- **Abgabe**: bis spätestens am 3.11.2026, 24:00 per email an eva.scheel-huber@uni-koeln.de
- **Abgabeformat**: R-Skript
- **benötigte Daten**: SUBTLEX-UK_selection.csv, auf Sciebo verfügbar

2 Datensatz

In diesem Arbeitsblatt verwenden wir *Subtlex-UK* (Heuven et al. 2014), welches englische Wörter und deren Häufigkeiten in britischen Fernsehsendungen enthält. Der Ausschnitt, mit dem ihr hier arbeiten wird, beschränkt sich auf die folgenden Variabeln:

- Wort
- Worthäufigkeit
- Lemma und die Wortkategorie (*part-of-speech (POS)*) dessen
- ein Maß für *Contextual Diversity (CD)*: Prozentsatz von Filmen, die das Wort enhalten

Für mehr Informationen zu dem Datensatz und für welche linguistische Fragestellungen dieser verwendet werden kann, schau dir den Artikel von Heuven et al. (2014) an.

3 Vorbereitung

Lade den Datensatz runter, erstelle ein neues RProjekt und öffne ein neues R-Skript. In diesem R-Skript wirst du die unten aufgelisteten Aufgaben und Fragen bearbeiten. In Kommentaren (`#`) kannst du im Skript angeben, welche Aufgabe oder Frage du mit dem Code erfüllst oder beantwortest.

Beispiel (erfunden):

```
# Aufgabe 10.2
data_new <- data |>
    mutate(new_column = 1:nrow(data))
```

Benutze gerne allgemein Kommentare, um deinen Code zu dokumentieren und besser verständlich zu machen.

4 Aufgaben

In diesem Aufgabenblatt wirst du die folgenden vier Schritte durchgehen: Daten einlesen, Daten untersuchen, Daten vorverarbeiten & "reinigen" und zuletzt die vorverarbeitete Daten speichern. Für manche Fragen/Teilaufgaben brauchst du Funktionen, die wir im Seminar noch nicht besprochen haben. Benutze die Informationsquellen, die im Kurs erwähnt wurden, um rauszufinden, wie man gewisse Schritte umsetzen kann.

1. **Daten einlesen**: Lese die *Subtlex-UK*-Daten als Data Frame in R ein.
2. **Daten untersuchen**
   2.1.Wie viele Zeilen und wie viele Spalten hat der Data Frame?
   2.2 Wie heißen die Spaltennamen?
   2.3 Gibt es leere Felder, sogenannte *NA*s?
3. **Daten vorverarbeiten**
   3.1 Für linguistische Studien (z.B. psycholinguistische Experimente wie Worterkennungsstudien) verwenden wir Worthäufigkeit oftmals auf der logarithmischen Skala. Füge also eine neue Spalte ein, die die Worthäufigkeit auf der logarithmischen Skala beinhaltet.
   3.2 Erstelle einen neuen Data Frame, welcher 1) nur Wörter beinhaltet, die mindestens zwei und höchstens zehn Charaktere lang sind und 2) keine Wörter beinhaltet, von denen die Wortkategorie (*pos*) "unclassified" ist.
   3.3 Ändere den neuen Data Frame so, dass er alle Spalten bis auf *Contextual Diversity* beinhaltet.
   3.4 Wie viele Zeilen und Spalten hat der neue Data Frame?
4. **Daten untersuchen mit `summarise()`**

   - Nun verwenden wir die Funktion `summarise()` von `dplyr` (aus der `tidyverse`-Sammlung), die wir in der letzten Sitzung noch nicht angetroffen haben.

- Mit `summarise()` können wir unsere Daten basierend auf gewissen Gruppen zusammenfassen. Die Gruppen beziehen sich dabei immer auf einzelne Spalten. Mit `data |> summarise(mean_per_pos = mean(FreqCount), .by=DomPoS)`[1] berechnet man z.B. die Durchschnittshäufigkeit (d.h. den *mean*) für jede Wortkategorie. Die Gruppe wird also in dem `.by`-Argument festgelegt. Die Funktion, die die Art der Zusammenfassung bestimmt, ist `mean()`.

- Probiere es nun selber aus und verwende `summarise()`, um die durchschnittliche Wortlänge für jede Wortkategorie zu berechnen.

5. **Daten speichern**
   5.1 Speichere den neuen Data Frame in einer Datei. Wähle einen passenden Dateinamen aus.

Quellen

Heuven, W. J. B. van, P. Mandera, E. Keuleers, and M. Brysbaert. 2014. "SUBTLEX-UK: A new and improved word frequency database for British English." *The Quarterly Journal of Experimental Psychology* 67: 1176–90. https://doi.org/https://doi.org/10.1080/17470218.2013.850521.

[1] Der folgende Code erzielt das gleiche Ergebnis: `data |> group_by(DomPoS) |> summarise(mean_per_pos = mean(FreqCount))`